

量化研究课程项目综合报告

中国商品期货横截面预测中的CNN模型 改进研究

从基础一维卷积网络到因果Conv-Transformer多任务框架

作者：刘梵佑

研究对象：2015-2025年中国商品期货日频数据

模型主线：1D-CNN、Conv-Transformer、多任务双头网络

报告日期：2026年7月

本报告依据项目文件夹中的代码、数据、运行摘要、审计文档与历史图表综合撰写。
对缺失源码、口径变化和无法与当前代码绑定的历史结果均作显式披露。

摘要

本文围绕中国商品期货横截面收益预测问题，对项目多轮卷积神经网络改进工作进行系统整理与方法复核。研究对象为30个商品期货品种，当前整合合约日表覆盖2015年1月5日至2025年12月31日，共846,963条“实际合约-交易日”记录、53个字段、2,674个交易日和3,753份合约。项目的技术路线由五因子基础一维卷积网络起步，依次经历未来收益标签延长、扩展窗口验证、信号平滑与换手缓冲、基于高斯混合模型的压力状态门控、Conv1d与Transformer Encoder融合、方向与幅度联合学习、59维特征接入，以及整合数据条件下的因果特征重建与统一评价审计。

当前代码的目标方法以20个交易日的59维特征序列为输入，由Conv1d提取局部模式、品种嵌入提供横截面身份信息、单层Transformer编码时间依赖，并使用分类头预测未来20日截面超额收益方向、回归头预测其幅度。训练采用2015年起点的扩展窗口，2022-2025年为预定样本外阶段；通过训练标签退出日约束、40日净化区间、训练日期每5日抽样、决策日与执行日分离等措施降低标签重叠和未来信息泄漏。组合层使用3日指数移动平均、动态分位入场、宽退出缓冲、流动性准入、预测强度加权和因果两状态GMM降杠杆机制。

对项目证据链的复核表明，历史结果能够说明研究迭代方向，但不能构成严格控制变量实验。版本3缺少对应源码，版本7目录中的脚本与版本5逐字节相同，版本6因旧59因子矩阵截至2024年而只有697个样本外交易日；同时，当前根目录代码已经切换至20日标签，而若干旧文档及旧结果仍采用5日标签。基于可核验的运行摘要，版本3在3个基点单边成本下年化收益为-5.55%、Sharpe为-0.689；版本5相应为0.35%与0.087；版本6为0.80%与0.147，但三者的数据、特征、模型和测试覆盖并不一致。历史实验共同显示，改进后的模型能够降低换手、改善毛收益，却仍对交易成本高度敏感，尚不足以支持稳定可交易的强结论。

本文的主要贡献是将分散的多版本工程材料重构为一条可审计的研究逻辑：先保证数据点时正确与评价口径一致，再讨论模型复杂度；同时严格区分“当前方法设计”“已运行的历史结果”和“尚待完成的新整合实验”。研究表明，未来改进重点不应只是叠加网络层数，而应转向标签与执行的一致性、特征稳定性、板块异质性、成本约束训练和真正同口径的消融实验。

关键词：商品期货；一维卷积神经网络；Transformer；多任务学习；横截面预测；扩展窗口回测；交易成本

证据口径说明

本报告将证据划分为三个层级。第一层为可直接从当前数据与代码核验的方法事实，包括现有CSV规模、当前配置、特征公式、模型前向传播、时间切分和交易规则。第二层为带有对应运行摘要或图表的历史实验事实，包括版本3、版本5与版本6的回测汇总，以及版本1、5、6的训练或回测图。第三层为文档陈述但缺少当前输出文件支持的历史数字，此类内容不作为当前模型正式结论。

报告中的“当前模型”专指根目录china_futures_ml_kaggle.py定义的整合数据、59维输入、20日标签版本；“历史模型”指版本文件夹中实际留存的脚本或运行摘要。现有根目录未保存与当前20日整合模型相绑定的futures_ml_outputs结果集，因此本文不虚构当前模型的年化收益、Sharpe、IC或最大回撤。凡引用旧图，图题均标明版本与限制，避免视觉材料被误解为当前模型的最终绩效。

目录

摘要	I
证据口径说明	II
1 研究背景与问题定义	1
1.1 研究背景	1
1.2 研究问题	1
1.3 研究设计原则	1
2 数据基础与研究样本	1
2.1 当前整合合约日表	2
2.2 品种池与板块结构	2
2.3 旧交接包及其边界	3
2.4 数据缺失与可交易性风险	3
3 因果主力合约、收益标签与防泄漏设计	3
3.1 因果主力合约选择	3
3.2 决策、执行与收益记账	4
3.3 标签重叠与净化区间	4

4 特征工程：从少量因子到59维输入	4
4.1 早期五因子基线	4
4.2 七个原始量价输入	5
4.3 当前45个连续特征	5
4.4 稳健横截面标准化与板块中性化	5
4.5 特征工程的经济逻辑	6
5 CNN模型的迭代路径	6
5.1 版本1：基础1D-CNN验证链路	6
5.2 版本3与版本4：标签延长、扩展窗口和风控	6
5.3 版本5：Conv-Transformer与多任务双头	7
5.4 版本6：旧59因子交接包	7
5.5 当前整合模型：数据契约优先于架构堆叠	8
6 最终模型结构与训练目标	8
6.1 输入与局部卷积表示	8
6.2 品种嵌入与信息融合	9
6.3 轻量Transformer Encoder	9
6.4 多任务损失与综合信号	9
6.5 核心训练超参数	10
7 扩展窗口训练与样本外评价	10
7.1 年度扩展窗口	10
7.2 预测评价	11
7.3 统计显著性	11
8 组合构建、交易成本与风险控制	11
8.1 信号平滑、入场和退出	11
8.2 预测强度加权	11
8.3 因果GMM压力门控	12
8.4 费用与换手定义	12
9 历史样本外结果与审慎比较	12
9.1 可核验的历史回测摘要	12

9.2 版本5的成本敏感性	13
9.3 版本6的净值与费用图	13
9.4 版本1的反例价值	14
9.5 不能作为当前结果使用的材料	14
10 统一评价与稳健性设计	14
10.1 统一指标面板	14
10.2 费用、持有期与信号延迟	15
10.3 板块与流动性稳健性	15
10.4 真正需要补充的消融实验	15
11 项目版本证据链与可复现性审计	15
11.1 版本证据表	15
11.2 文档不一致及处理	16
11.3 建议的复现清单	17
12 讨论	17
12.1 模型复杂度与信号强度	17
12.2 多任务学习的价值与风险	17
12.3 特征多样性与非平稳性	17
12.4 经济显著性先于统计显著性	18
12.5 风险门控的解释边界	18
13 局限性与后续研究	18
13.1 现有材料的局限	18
13.2 下一阶段的实验优先级	18
14 结论	19
A 当前59维输入清单	20
A.1 45个连续特征	20
A.2 14个缺失质量标志	21
B 30品种研究池	21

C 历史结果完整费用表	22
D 正式新实验的建议输出结构	22

插图目录

1 基础CNN的训练曲线与特征重要性。该图仅用于说明早期基线，不代表当前模型。	6
2 版本5多任务Conv-Transformer的扩展窗口训练曲线。虚线验证损失在若干年份后期回升，提示早停和时间验证的重要性。	7
3 版本6旧59因子模型的训练与验证损失。图中仅覆盖旧交接包可形成的测试折。	8
4 版本6旧59因子模型的历史回测图。由于2025年特征缺失，图中结果只对应2022-2024年。	13
5 版本1基础CNN的历史费用敏感性。毛收益已经较弱，费用进一步放大亏损。	14

表格目录

1 当前整合合约日表的可核验概况	2
2 当前整合模型的核心配置	10
3 当前预定的年度扩展窗口	10
4 历史版本的样本外回测摘要（不同协议，不构成严格消融）	12
5 项目版本演进及证据边界	15
6 当前整合模式的45个连续特征	20
7 当前代码固定的30品种研究池	21
8 版本3、5、6在不同单边费用下的历史结果	22

1 研究背景与问题定义

1.1 研究背景

商品期货收益同时受到趋势延续、期限结构、库存与仓单、交易拥挤、流动性及宏观风险状态影响。传统线性因子模型具有较强解释性，但难以自然表达多周期非线性、变量间交互和状态依赖。深度神经网络能够从特征序列中提取局部形态并进行非线性组合，因此逐渐成为资产定价与量化选股、择时研究的重要工具[3, 4]。然而，金融时间序列的低信噪比、非平稳性、横截面样本有限和交易成本侵蚀，使“模型拟合能力提升”并不等于“样本外经济价值提升”。

一维卷积网络适合处理固定长度特征序列。卷积核共享参数，可在不同时间位置识别相似的局部变化模式，较全连接网络更节省参数；扩张卷积或多层卷积还能扩大感受野。Transformer通过自注意力建立任意时间位置间的依赖[4]，弥补局部卷积对远距离关系建模不足。二者融合的直觉是：先用卷积形成局部表示，再用轻量注意力完成全局聚合。不过，在只有20日序列且横截面约30个品种的场景下，网络必须控制维度与层数，否则容易在有限样本上过拟合。

1.2 研究问题

本项目的核心问题不是单纯寻找历史收益最高的模型，而是检验在严格点时约束和统一交易协议下，CNN及其扩展结构能否从中国商品期货的多维日频信息中预测未来截面相对收益。更具体地说，研究需要回答四个相互关联的问题：局部时序卷积能否提取具有样本外稳定性的模式；注意力与多任务学习是否改善方向和幅度的联合刻画；多源特征相较少量价格量因子是否提供增量信息；模型信号在费用、换手、流动性与压力状态约束下是否仍具有经济价值。

1.3 研究设计原则

项目演进逐渐形成四项设计原则。第一，特征形成时间必须早于交易执行时间，主力合约选择也只能使用当时可获得的信息。第二，训练、验证和测试必须按时间推进，不允许随机切分。第三，预测指标与组合指标同时报告，不能只用净值曲线替代统计检验。第四，版本比较必须保持数据、标签、测试区间和交易规则一致；若条件不一致，只能作为探索性历史证据，不应解释为严格的架构消融。

2 数据基础与研究样本

2.1 当前整合合约日表

当前默认数据文件为futures_contract_daily_30varieties_2015_2025.csv。逐行核验结果见table 1。其粒度是“某份实际期货合约在某个交易日的一行”，键trade_date + ts_code没有重复。相较把主力连续价格作为唯一输入，合约级数据允许研究者在每个历史日期重新选择可交易主力、计算次主力期限结构，并在换月时区分合约价格跳跃和真实持有收益。

表 1: 当前整合合约日表的可核验概况

项目	数值
数据日期范围	2015-01-05至2025-12-31
实际合约-交易日记录	846,963
字段数量	53
交易日数量	2,674
期货品种数量	30
实际合约数量	3,753
唯一键重复数	0
当前预定样本外年份	2022-2025

数据字段覆盖合约代码、品种、交易所、合约月份、上市与退市日期、合约乘数、开高低收、结算价、成交量、成交额、持仓量、手续费、保证金、现货价格、仓单、库存及其观测日期和陈旧天数。基本面字段并非每天更新，因此“数值存在”不代表“信息新鲜”。当前特征工程对现货使用30日最大陈旧阈值，对仓单使用45日，对库存及可用库存使用60日；超过阈值的观测被视为缺失，并由质量标志提示模型。

2.2 品种池与板块结构

当前研究池固定为30个品种，覆盖黑色产业链、有色金属、贵金属、能源化工、建材化工和农产品。与旧59因子交接包相比，当前池增加CS、L、SF、SN，移除EG、FG、OI、RU。这意味着旧交接矩阵不能通过关闭严格校验直接与当前面板拼接，否则不同品种的缺失会与时间变化混合，形成不可解释的样本选择偏差。

品种嵌入将30个品种映射为8维可学习向量，使共享网络在处理同样的标准化特征时保留品种身份。其意义不是让模型记忆某一品种的固定收益，而是允许相同局部模式在农产品、金属或能源化工中拥有不同条件响应。为了减少直接的板块暴露，当前连续特征在每日横截面稳健标准化后还进行板块去均值。

2.3 旧交接包及其边界

旧training_handoff交接包包含2015–2024年69,916条品种日记录、59个输入字段、1日/5日/20日标签、因子注册表、筛选报告与审计文件。该包对研究方法仍有价值：它展示了从57个概念因子到59个机器学习输入的筛选、缺失标记与相关性聚类流程。但它不含2025年特征，并且品种池与当前整合表不同。因此，版本6的2025测试折自然为空，历史结果只覆盖2022–2024年。

2.4 数据缺失与可交易性风险

当前合约级CSV的库存、可用库存和部分费用字段缺失较多。库存相关字段缺失率约为63.35%，可用库存约为55.20%，费率字段约为59.66%。这些缺失并不必然意味着数据质量差，因为不同品种的信息披露制度和更新频率不同；但若直接零填充，模型会把“没有观测”误解为“经济含义为零”。当前方案先保留缺失位置，再对连续特征填零，并通过14个质量标志向网络暴露数据可用性。该处理仍不能完全解决披露机制变化问题，报告结果时应将基本面覆盖率漂移视为潜在非平稳来源。

3 因果主力合约、收益标签与防泄漏设计

3.1 因果主力合约选择

传统主力连续序列常按当日成交量或持仓量事后选择主力，如果同日收盘信号又使用该序列，则主力身份可能包含收盘后才能确认的信息。当前代码使用滞后成交量和持仓量形成活跃度，并设置换月阈值：候选后月合约的活跃度需超过当前合约的1.10倍才切换，同时限制临近到期合约并避免无理由滚回近月。这样，决策日 t 的特征只依赖 t 及以前已经可观察的数据。

设品种 i 在日期 t 的候选合约集合为 $C_{i,t}$ ，滞后活跃度为

$$A_{c,t-1} = g(V_{c,t-1}, OI_{c,t-1}), \quad (1)$$

其中 V 与 OI 分别表示成交量和持仓量。主力切换不仅要求候选合约活跃度最大，还需满足最小剩余期限和相对活跃度条件。该规则牺牲部分换月及时性，换取更清晰的点时可用性。

3.2 决策、执行与收益记账

信号在决策日 t 收盘后形成，于下一交易日 $t + 1$ 开盘执行。当前主标签为从 $t + 1$ 开盘开始的未来20段open-to-open收益的几何累计：

$$R_{i,t}^{(20)} = \prod_{h=1}^{20} (1 + r_{i,t+h}^{\text{oo}}) - 1. \quad (2)$$

每一天的 r^{oo} 使用当时因果选择的实际主力合约，以减少主力换月价差被误计为收益的问题。回归目标为执行日横截面去均值后的超额收益：

$$y_{i,t}^{\text{reg}} = R_{i,t}^{(20)} - \frac{1}{N_{t+1}} \sum_{j=1}^{N_{t+1}} R_{j,t}^{(20)}, \quad (3)$$

分类目标为

$$y_{i,t}^{\text{cls}} = \mathbb{I}(y_{i,t}^{\text{reg}} > 0). \quad (4)$$

需要区分标签周期和回测记账周期。虽然当前模型预测未来20日累计超额收益，组合仍逐日使用下一段可交易open-to-open收益计算盈亏；入场与退出由动态分位和缓冲带决定，不是机械固定持有20日。因此，“20日标签”不能简写成“每20日调仓”或“固定持有20日”。

3.3 标签重叠与净化区间

相邻日期的20日标签共享大量未来收益，若每天都作为独立训练样本，会夸大有效样本量并使验证损失过于乐观。当前训练期每5个交易日保留一个完整品种横截面，验证和测试保持逐日预测。训练内部按时间尾部15%划分验证集，并在拟合集与验证集之间保留40日净化区间。外层年度折还要求训练样本的`exit_date`严格早于测试年起点，从而防止年末训练标签跨入测试期。

这种设计仍不等于完全独立样本。5日抽样后，相邻训练标签仍可能重叠15日，因此显著性分析不能采用独立同分布标准误。项目评价层使用Newey-West/Bartlett异方差自相关稳健标准误[5]和圆形块自助法，正是为了处理剩余序列依赖。

4 特征工程：从少量因子到59维输入

4.1 早期五因子基线

版本1使用动量、期限结构、20日波动率、流动性与20日偏度五类输入。每个样本由过去20日因子序列构成，输入形状为 $[B, 5, 20]$ 。该设计简单、易解释，适合验证从数据发现、主力合约、序列样本、CNN训练到多空回测的端到端链路。其局限在于特

征维度低、对基本面与持仓变化利用不足，并且早期目标仅为下一日收益，日频噪声较强。

4.2 七个原始量价输入

版本5一度将输入改为七个原始变换：开盘相对收盘、高点相对收盘、低点相对收盘、收盘相对前收、成交量变化、持仓量变化与roll yield。这样做的动机是减少人工因子假设，让Conv-Transformer自行组合局部形态。优点是输入定义直接，缺点是模型需在有限样本上同时学习尺度、经济含义和时序组合，可能增加样本复杂度。

4.3 当前45个连续特征

当前整合模式从因果主力面板重建45个连续特征。价格与趋势部分包括1日收益，5、10、20、60、120日动量，20、60、120日趋势效率；风险形态包括5、10、20、60、120日实现波动率、20日下行波动率、20和60日偏度、日内振幅、K线实体及收盘-结算价差；交易与流动性包括对数成交量、成交量1日和5日变化、20与60日成交量 z 分数、对数持仓量、持仓量1日和5日变化、20与60日持仓量 z 分数、成交量-持仓量换手率和20日Amihud非流动性。

期限结构部分包含roll yield及其5日、20日变化。基本面部分包含现货5日与20日动量，仓单、库存、可用库存各自的60日水平标准分与5日变化，并额外加入仓单和库存1日冲击。与旧交接包中的59字段不同，当前59维输入不是旧注册表的同名复制，而是“45个新连续特征+14个缺失质量标志”。

4.4 稳健横截面标准化与板块中性化

连续特征首先按品种进行只依赖历史的时间序列变换。随后在每个交易日计算横截面中位数 $m_{k,t}$ 和中位绝对偏差 $MAD_{k,t}$ ，对特征 k 进行稳健标准化：

$$z_{i,k,t} = \text{clip} \left(\frac{x_{i,k,t} - m_{k,t}}{1.4826 \text{ MAD}_{k,t}}, -8, 8 \right). \quad (5)$$

若MAD过小，则回退使用当日横截面标准差。标准化后，再减去同日同板块均值：

$$\tilde{z}_{i,k,t} = z_{i,k,t} - \frac{1}{|\mathcal{S}_{i,t}|} \sum_{j \in \mathcal{S}_{i,t}} z_{j,k,t}, \quad (6)$$

其中 $\mathcal{S}_{i,t}$ 为品种 i 所属板块在日期 t 的可用集合。最终缺失连续值填为零，并保留缺失标志。这个零代表“当日横截面中性且信息缺失”，必须与质量标志共同解释。

4.5 特征工程的经济逻辑

特征体系试图把商品期货收益的三类来源放入统一张量。第一类是价格路径与风险状态，如动量、趋势效率、波动率和偏度；时间序列动量在多类资产中具有广泛经验依据[2]。第二类是期限结构与库存补偿，roll yield和曲线变化反映便利收益、融资持有成本及供需紧张程度。第三类是交易行为与信息质量，成交量、持仓量、Amihud指标和缺失标志描述拥挤、流动性及披露差异。CNN与注意力的作用不是替代这些经济逻辑，而是在20日窗口中寻找其非线性共同变化模式。

5 CNN模型的迭代路径

5.1 版本1：基础1D-CNN验证链路

版本1采用三层卷积通道(32, 64, 128)，dropout为0.15，使用Huber损失回归未来收益。该阶段的价值主要是建立可运行基线：因果主力合约、5个因子、20日序列、滚动训练、费用敏感性和置换重要性均已形成。由于首个测试年为2020年，测试区间与后续2022年起点不同，且标签为下一日收益，版本1图表不应与后续5日或20日模型直接比较。




图 1: 基础CNN的训练曲线与特征重要性。该图仅用于说明早期基线，不代表当前模型。

fig. 1显示早期模型在若干折中迅速收敛，置换重要性以20日波动率最突出，其次为动量、偏度和流动性。由于置换重要性是在相关特征存在时逐列打乱得到，它反映的是条件预测贡献，而非经济因果效应。早期净值明显下行，说明训练损失收敛不能保证经济收益。

5.2 版本3与版本4：标签延长、扩展窗口和风控

版本3将预测目标从次日收益延长至未来5日累计超额收益，并把验证改为扩展窗口。模型使用不压缩时间维度的轻量卷积结构，组合加入3日EMA和平滑持仓缓冲。版本3缺少对应源码，当前只能从更新记录、损失图和回测摘要重建其概况，不能复现所有细节。

版本4保留5日目标，将数据起点压缩到2018年，首个测试年固定为2022年；组合从等权变为预测强度加权，并新增由市场波动率、平均相关性和流动性压力构成的两状态GMM。每个测试年只使用其之前的数据拟合标准化器和GMM，高压概率超过0.8时将组合毛杠杆降为50%。这一阶段的改进重点从“预测模型”扩展为“预测-组合-风控”完整系统。

5.3 版本5: Conv-Transformer与多任务双头

版本5把卷积网络改造为Conv1d局部嵌入与单层Transformer Encoder的组合，并加入分类、回归双头。模型使用7个原始量价特征，维度48、注意力头数4、前馈层维度96、dropout为0.10。分类头学习超额收益正负，回归头学习幅度；两个目标共同约束共享表示，从而避免只优化连续收益时被极端值主导。




图 2: 版本5多任务Conv-Transformer的扩展窗口训练曲线。虚线验证损失在若干年份后期回升，提示早停和时间验证的重要性。

从fig. 2可见，训练损失继续下降时，部分验证折在较早轮次后转为上升，说明注意力结构虽增强表达能力，也扩大了过拟合空间。项目采用最多40轮、耐心值7的早停机制，再按选定轮数在完整训练窗上重拟合。该做法避免测试集参与轮数选择，但模型超参数本身仍可能受多轮历史实验影响，因此最终结论仍需独立封存测试或严格预注册。

5.4 版本6: 旧59因子交接包

版本6沿用版本5架构，将输入从7个原始变量扩展为旧交接包注册表中的59个字段，并把dropout提高到0.40。旧特征已经完成同日横截面MAD标准化、缺失填零与质量标志加工。模型输入由 $[B, 7, 20]$ 变为 $[B, 59, 20]$ ，这使卷积核在每个局部时间片可以联合组合更多经济维度。

版本6的主要问题是数据契约不完整：特征截至2024年，且品种池与后来的整合池不同。因此其样本外结果只包含2022–2024年，共697个交易日。该版本不能证明“59因子一定优于7个原始变量”，因为输入、覆盖年份、品种与dropout同时变化；但它验证了59维特征张量可以稳定接入多任务网络，并显著降低历史回测换手。




图 3: 版本6旧59因子模型的训练与验证损失。图中仅覆盖旧交接包可形成的测试折。

5.5 当前整合模型：数据契约优先于架构堆叠

当前根目录模型保持轻量Conv-Transformer双头，但对数据与训练逻辑作出关键修正：数据起点恢复为2015年；品种池调整为当前30品种；59维输入改由整合合约日表重新生成；标签从5日切换为20日；净化间隔从25日增至40日；品种Embedding真正传入训练和预测流程；权重衰减提高至 10^{-3} ；入场加入最低20%流动性限制，退出使用40%/60%宽缓冲带。

从研究设计角度看，这些修改比继续增加Transformer层数更重要。金融深度学习中，错误的数据时间戳或不一致的品种池足以产生远大于模型结构差异的虚假优势。当前版本的首要贡献是建立一套可以重新运行和统一评价的数据契约，而不是声称已经取得优异收益。

6 最终模型结构与训练目标

6.1 输入与局部卷积表示

输入张量记为 $\mathbf{X} \in \mathbb{R}^{B \times F \times T}$ ，其中 $F = 59$ ， $T = 20$ 。Conv1d使用核宽3、padding 1，把59个输入通道映射到48维局部表示：

$$\mathbf{H}^{(0)} = \text{Dropout}(\text{GELU}(\text{Conv1d}_{k=3}(\mathbf{X}))). \quad (7)$$

卷积输出转置为 $B \times T \times D$ 。每个时间位置共享同一组卷积参数，使网络能够识别连续几日中相似的特征共振，例如动量上升伴随持仓增加、波动下降或期限结构收紧。

6.2 品种嵌入与信息融合

对每个样本的品种编号 p_i ，模型查表得到8维嵌入 e_{p_i} ，并在20个时间位置重复。局部表示与品种嵌入拼接后经线性层投影回48维：

$$\mathbf{H}_{i,t}^{(1)} = \mathbf{W}_f \left[\mathbf{H}_{i,t}^{(0)}; e_{p_i} \right] + \mathbf{b}_f. \quad (8)$$

该嵌入将“共享规律”和“品种条件差异”同时交给下游注意力。由于横截面只有30个品种，嵌入维度控制为8，避免品种身份参数过多。

6.3 轻量Transformer Encoder

单层Transformer含4头自注意力和96维前馈网络。对第 h 个注意力头，

$$\text{Attention}_h(\mathbf{Q}_h, \mathbf{K}_h, \mathbf{V}_h) = \text{softmax}\left(\frac{\mathbf{Q}_h \mathbf{K}_h^\top}{\sqrt{d_h}}\right) \mathbf{V}_h. \quad (9)$$

模型使用batch-first和pre-norm结构，激活函数为GELU，dropout为0.40。20日窗口较短，单层注意力已经能够建立全局位置关系；继续增加层数会显著增加方差，却未必提供更多有效时间尺度。

Transformer输出经过时间平均池化、LayerNorm与dropout，得到共享向量 $\mathbf{h}_i$ 。分类头输出logit a_i ，回归头输出 $\hat{y}_i^{\text{reg}}$ ：

$$a_i = \mathbf{w}_c^\top \mathbf{h}_i + b_c, \quad \hat{y}_i^{\text{reg}} = \mathbf{w}_r^\top \mathbf{h}_i + b_r. \quad (10)$$

6.4 多任务损失与综合信号

总损失由二元交叉熵和Huber损失构成：

$$\mathcal{L} = 0.7 \mathcal{L}_{\text{BCE}}(a, y^{\text{cls}}) + 0.3 \mathcal{L}_{\text{Huber}}(\hat{y}^{\text{reg}}, y^{\text{reg}}). \quad (11)$$

分类任务强调排序方向，回归任务保留幅度。最终预测信号为

$$s_i = \sigma(a_i) \hat{y}_i^{\text{reg}}. \quad (12)$$

该乘积并非严格的条件期望分解，因为回归头训练目标没有显式限定在正收益条件下；它更接近一个经验门控：分类概率抑制低置信度的回归幅度。未来可以比较 s_i 、

纯回归输出、概率中心化乘幅度等信号定义，以确认门控本身是否贡献增量信息。

6.5 核心训练超参数

表 2: 当前整合模型的核心配置

配置项	当前值
输入形状	$[B, 59, 20]$
卷积核与模型维度	$k = 3, D = 48$
品种嵌入维度	8
注意力头数 / Encoder层数	4 / 1
前馈维度	96
Dropout	0.40
Batch size	512
最大训练轮数 / 早停耐心	40 / 7
学习率 / 权重衰减	$10^{-3} / 10^{-3}$
分类损失权重	0.70
训练日期抽样步长	5个交易日
训练内部验证比例	15%
净化区间	40个交易日
随机种子	42

7 扩展窗口训练与样本外评价

7.1 年度扩展窗口

首个外层折以2015–2021年作为可用训练历史，2022年作为测试期；随后依次形成2015–2022预测2023、2015–2023预测2024、2015–2024预测2025的扩展窗口。扩展窗口保留全部历史，适合样本量有限的深度模型，但隐含旧制度数据仍有价值的假设。当市场结构发生突变时，固定长度滚动窗口可能更适合，因此二者应在同一协议下作为稳健性比较，而不是预先认定扩展窗口更优。

表 3: 当前预定的年度扩展窗口

测试折	训练历史	样本外测试
1	2015–2021	2022
2	2015–2022	2023
3	2015–2023	2024
4	2015–2024	2025

每折先在训练窗内部进行时间验证和早停轮数选择，再用该轮数在完整训练窗上重拟合。置换重要性在对应测试样本上计算，并跨折求均值。模型保存的最佳检

查点依据内部验证损失选择，而不是依据样本外收益，避免显式用测试净值选择模型。

7.2 预测评价

横截面预测能力应同时用Pearson IC和Spearman Rank IC评估：

$$IC_t = \text{corr}_i(s_{i,t}, R_{i,t}^{(H)}), \quad \text{RankIC}_t = \text{corr}_i(\text{rank } s_{i,t}, \text{rank } R_{i,t}^{(H)}). \quad (13)$$

Pearson IC对幅度和极端值更敏感，Rank IC更关注排序。报告均值时还应给出标准差、未年化ICIR、分年结果、IC大于0.02与小于-0.02的频率。五分组收益单调性可以帮助判断模型是否只在尾部有效，或是否根本没有形成稳定排序。

7.3 统计显著性

由于日度收益和重叠标签具有自相关，普通 t 检验可能低估标准误。项目评价层对日度收益和IC使用HAC标准误，并以20日块长、1,000次重复的圆形块自助法给出95%区间。该设计优于只报告Sharpe，但仍需注意：模型选择过程本身进行了多次尝试，单一最终策略的 p 值没有计入数据窥探和多重比较成本。若未来将版本比较写成正式统计结论，应预先定义候选模型集，或采用现实检验、SPA等数据窥探修正方法。

8 组合构建、交易成本与风险控制

8.1 信号平滑、入场和退出

模型原始信号先按品种计算3日指数移动平均。每天在可用横截面中，多头候选为信号位于前30%且大于零的品种，空头候选为后30%且小于零的品种。已有多头只有跌破40%分位才退出，已有空头只有升破60%分位才退出。这种进入门槛严、退出门槛宽的滞后缓冲能够减少信号在边界附近反复翻转。

决策日流动性最低20%的品种禁止新开仓，但已有仓位不被强制平仓，仍按退出线处理。流动性准入优先使用成交量、成交额或滞后活跃度中可覆盖足够品种的字段。该规则是可交易性近似，并未完整模拟盘口深度、涨跌停或冲击成本。

8.2 预测强度加权

多空两侧分别按信号绝对强度减去侧内最小值后归一化。正常状态下每侧目标毛敞口为0.5，理论总毛敞口为1；若某一侧没有满足阈值的品种，允许保留现金，而不是强制凑足对称头寸。这一设计避免弱信号品种因为截面名额被动入选，也使净敞口可能偏离零，故结果分析应同时报告净敞口和毛敞口。

8.3 因果GMM压力门控

每日系统压力特征由过去20日市场波动、品种平均相关性和流动性压力构成。对测试年 Y ，StandardScaler和两状态Gaussian Mixture Model只使用 Y 年之前的历史拟合；测试年仅执行变换和状态概率预测。将三个标准化特征均值总和更高的分量解释为压力态。若压力概率超过0.8，则每侧毛敞口从0.5降为0.25，总毛杠杆乘数为0.5。

GMM门控是无监督风控，并不保证识别出的高均值分量在每个时期都对应经济压力。未来应报告门控启动比例、门控前后收益、错过的上涨区间和回撤改善，而不能仅因最大回撤下降就认定状态识别有效。

8.4 费用与换手定义

令 $w_{c,t}$ 为实际合约 c 在 t 日开盘后的目标权重，则绝对交易量为

$$A_t = \sum_c |w_{c,t} - w_{c,t-1}|, \quad (14)$$

报告换手率为 $\text{Turnover}_t = A_t/2$ 。单边费用 f 下的净收益为

$$r_t^{\text{net}} = r_t^{\text{gross}} - f A_t. \quad (15)$$

历史脚本报告1、3、5个基点单边成本；统一评价层计划报告0、3、5、10个基点。固定基点模型便于跨版本比较，但不能完整覆盖按手计费、平今差异、交易所与期货公司加收、保证金占用、盘口冲击和容量限制。

9 历史样本外结果与审慎比较

9.1 可核验的历史回测摘要

当前可直接核验的汇总结果来自版本3、版本5和版本6的result.txt。table 4列出毛收益与3个基点单边成本情景。版本3与版本5均有924个交易日，版本6只有697个交易日。由于版本3缺源码、版本6缺2025特征，且三者输入与交易规则不完全相同，表格只能说明项目迭代期间的历史表现范围。

表 4: 历史版本的样本外回测摘要（不同协议，不构成严格消融）

版本	观测日	毛年化收益	毛Sharpe	3bp年化收益	3bp Sharpe	3bp最大回撤
版本3	924	-3.4095%	-0.4040	-5.5456%	-0.6892	-26.3627%
版本5	924	2.5131%	0.4264	0.3528%	0.0875	-11.0240%
版本6	697	1.9579%	0.3074	0.7982%	0.1470	-16.6441%

从探索性角度看，版本5相较版本3由负收益转为微弱正收益，说明“更长标签+多任务表示+新的组合规则”这一整套改动值得继续研究；但不能把差异单独归功于Transformer。版本6的3bp年化收益高于版本5，同时平均日换手从0.14088下降到0.075664，但测试少一年、品种池和特征源不同，也可能解释部分差异。

9.2 版本5的成本敏感性

版本5毛年化收益为2.5131%，1bp单边成本后降至1.7879%，3bp后仅0.3528%，5bp后转为-1.0621%。这说明历史信号的毛收益空间与交易摩擦处于同一数量级。若策略只在极低成本假设下盈利，其价值更接近一个弱预测因子，而不是可直接实施的交易方案。

9.3 版本6的净值与费用图




图 4: 版本6旧59因子模型的历史回测图。由于2025年特征缺失，图中结果只对应2022–2024年。

fig. 4显示版本6在2023年中出现显著回撤，随后于2024年修复。费用曲线间距相对版本1缩小，与较低换手一致，但5bp情景的年化收益仅0.0323%、Sharpe为0.0401，接近零。策略改善主要表现为成本侵蚀减弱，而不是形成高强度的预测优势。

9.4 版本1的反例价值




图 5: 版本1基础CNN的历史费用敏感性。毛收益已经较弱，费用进一步放大亏损。

fig. 5提供了重要反例：网络训练曲线能够稳定下降、置换重要性也能产生看似清晰的排序，但样本外净值长期下行。该现象说明金融模型评价必须以时间外预测和成本后收益为中心，不能以训练收敛或特征重要性图替代经济检验。

9.5 不能作为当前结果使用的材料

版本7文件夹保留了一组上行净值和费用图，但其中脚本与版本5脚本哈希完全相同，不能证明这些图由标称“版本7整合数据代码”生成。教师版旧报告中的5日IC、成本情景和稳健性数字也与当前20日代码不一致，且根目录缺少对应输出表。因此，本报告不把这些数值写入当前模型主结果，也不据此宣称当前20日模型已经完成训练。

10 统一评价与稳健性设计

10.1 统一指标面板

当前代码在原预测、持仓和回测文件保存后运行独立评价层。计划输出累计收益、年化收益、年化波动、Sharpe、最大回撤、Calmar、平均换手、Pearson IC、Rank IC、IC标准差、未年化ICIR、HAC统计量、块自助区间与五分组单调性。评价层失败不会阻止原模型结果落盘，这一工程安排有利于保存长时间训练成果。

10.2 费用、持有期与信号延迟

统一费用情景为0、3、5、10bp单边成本。持有期稳健性拟比较1、5、20日未来收益上的IC与Rank IC，信号延迟稳健性则把预测整体延迟一个市场交易日。若信号在延迟后迅速消失，可能表明信息半衰期极短或执行时间假设过于乐观；若仍保持稳定，则更支持其为持续横截面信息。

持有期检验必须与主标签明确区分。当前训练目标是20日，1日和5日指标应被视为跨周期泛化测试，而不是从同一模型中选择最有利周期后替换主结论。所有稳健性结果都应完整展示，不应只报告表现最好的子样本。

10.3 板块与流动性稳健性

分板块评价用于识别模型是否主要依赖某个产业链。30个品种在细分后每组横截面较小，因此板块IC方差会显著上升；结果应同时给出观测数与置信区间。流动性稳健性通过剔除每日最低20%样本检验信号是否集中在难交易品种。如果剔除后预测能力提高，说明流动性噪声可能掩盖信号；如果显著下降，则可能存在不可实施收益。

10.4 真正需要补充的消融实验

现有历史版本不是严格消融。未来应固定同一整合数据、同一20日标签、同一2022–2025测试折和同一组合规则，只改变一个因素。核心消融包括：纯CNN与Conv-Transformer；单回归头与双头；无品种嵌入与有嵌入；7维原始特征、45维连续特征、59维含质量标志；无GMM与GMM门控；等权与信号强度加权；无缓冲与宽缓冲。每个实验应保存配置哈希、数据哈希、随机种子和逐折指标。

11 项目版本证据链与可复现性审计

11.1 版本证据表

表 5: 项目版本演进及证据边界

版本	主要改动	留存证据	可用于报告的范围
1	五因子、20日序列、基础1D-CNN、次日目标	完整脚本及损失、净值、费用、重要性图	可说明初始链路和失败基线；测试从2020年开始，不与后续直接比较

版本	主要改动	留存证据	可用于报告的范围
3	5日累计超额收益、扩展窗口、EMA和持仓缓冲	回测摘要与损失图，无源码	可引用汇总数字，但不能精确复现或做结构归因
4	2018起点、预测强度加权、因果GMM压力门控	完整脚本，无结果摘要	可说明方法改进，不能报告其绩效
5	七个原始量价输入、Conv-Transformer、多任务双头	完整脚本、损失图、回测摘要	可作为历史核心版本，但与版本3的变化不止模型结构
6	旧交接包59因子、dropout 0.40	脚本、README、四图、回测摘要、交接包	可报告2022–2024历史结果；不可视为当前30品种整合模型
7	文档称整合数据成为默认源	目录含图，但脚本与版本5完全相同	目录脚本不能作为版本7实现证据，图仅作未绑定历史材料
当前	整合CSV重建59特征、20日标签、品种嵌入、评价层	当前脚本、数据、方法文档，无对应正式输出	可完整写方法与预定评价；不得虚构绩效

11.2 文档不一致及处理

项目README首段仍写未来5日标签，但同一文件后文和当前代码均明确为20日；本报告以可执行配置`forecast_horizon=20`为准。旧教师报告写整合行情817,555行，而当前实物CSV为846,963行；本报告以对现有文件的直接计数为准。旧教师报告称已经完成2015–2025训练，但README、运行状态文档与当前目录均不支持这一陈述；本报告因此将当前结果状态定义为“方法完成、正式新结果待生成”。

这种处理不是否定旧工作，而是把研究叙事建立在可复核证据上。课程报告的可信度不仅取决于收益高低，也取决于是否准确说明数据版本、失败尝试和不可比较之处。

11.3 建议的复现清单

一次可用于正式结论的新运行应同时保存主脚本哈希、整合CSV哈希、Python与依赖版本、完整配置JSON、控制台日志、各折训练历史、样本外预测、逐日持仓、逐日回测、压力概率、模型权重和统一评价表。每个输出目录应使用实验ID或时间戳，避免新训练覆盖旧结果。图表必须从同一输出目录自动生成，不应在文档中手工混用不同版本图片。

运行前还应固定主协议：当前代码是20日标签、3bp基准成本、2015年训练起点和2022–2025测试。若课程要求改用5日预测，应修改代码、净化区间、训练抽样与评价口径后统一重跑，而不能直接把旧5日结果拼接到当前20日方法章节。

12 讨论

12.1 模型复杂度与信号强度

项目从基础CNN升级到Conv-Transformer双头，训练稳定性和历史毛收益有所改善，但成本后优势仍然有限。这符合金融预测的典型特征：深度模型可以降低表示偏差，却无法消除标签噪声、市场状态漂移和有限横截面带来的估计方差。20日窗口只有20个时间位置，单层注意力已经具有全局感受野；继续堆叠层数可能主要增加自由度，而不是增加可识别经济信息。

未来模型改进应以同口径消融为前提。若Transformer相对纯CNN在多个随机种子、多个年度折和费用后指标上都稳定提高，才能认为全局注意力具有增量价值。若提升只出现在某一年或某个成本假设下，则更可能是状态依赖或选择偏差。

12.2 多任务学习的价值与风险

方向分类与幅度回归具有互补性。分类头对极端幅度不敏感，能够强调排序；Huber回归头比平方误差稳健，又保留收益大小。0.7与0.3的权重是经验设定，并非理论最优。分类标签由回归目标符号派生，两个任务高度相关，可能只形成重复监督。未来可用动态损失权重、梯度冲突诊断或把第二任务改为波动调整收益、分位数等更具差异的信息目标。

12.3 特征多样性与非平稳性

当前59维特征涵盖价格、风险、交易行为、期限结构和基本面，信息源比早期模型丰富。与此同时，库存、仓单和现货的更新频率、覆盖品种和披露制度存在差异。模型可能学习到数据可用性本身，而非经济变量。质量标志可以降低零填充歧义，却不能保证缺失机制稳定。应按年份和品种绘制覆盖率，检查重要性是否集中于缺失标志，并对基本面特征做“仅高覆盖期”“剔除陈旧值”“完全不含基本面”的

消融。

12.4 经济显著性先于统计显著性

历史结果的共同特征是费用敏感。版本5在5bp成本下已经转负，版本6在5bp下接近零。即使无成本收益统计上略为正，也必须先问其单位换手收益是否足以覆盖真实交易摩擦。降低换手有两种路径：组合端加缓冲、平滑和阈值，模型端则可以直接优化成本调整目标或预测更长周期。前者可能把弱信号平滑成较低频暴露，后者才可能提高每次交易的信息含量。

12.5 风险门控的解释边界

GMM压力门控使用历史拟合，避免了直接未来泄漏，是本项目较成熟的风险控制设计。但它只依据三项市场统计量，无法覆盖政策冲击、涨跌停、保证金调整或跨品种传染。门控降低杠杆会同时减少回撤和上涨收益；若只比较最大回撤，结论可能偏向风控机制。应报告门控前后的收益、波动、Sharpe、Calmar、门控天数和机会成本，并检验压力阈值0.8是否稳健。

13 局限性与后续研究

13.1 现有材料的局限

首先，历史版本的证据完整度不一致。版本3没有源码，版本4没有结果，版本7脚本错存为版本5副本，导致无法重建一条完全可执行的逐版本链。其次，历史结果不满足统一实验协议，不能分离标签、特征、网络和组合规则各自的贡献。再次，当前20日整合模型尚无可核验的正式输出，本文只能完成方法综合与历史证据分析，不能给出当前模型绩效结论。

数据层面，合约级记录中部分行情和基本面字段缺失较高，现货与库存存在陈旧观测。交易层面，固定基点费用没有模拟真实按手收费、平今费用、涨跌停、冲击成本、容量与保证金。统计层面，多轮版本试验带来数据窥探风险，HAC或块自助法只修正时间依赖，不能自动修正模型选择偏差。

13.2 下一阶段的实验优先级

下一阶段应先冻结当前数据与20日主协议，完整运行2022-2025扩展窗口，并生成统一评价表。随后建立最小但严格的消融矩阵：纯CNN、Conv-Transformer、带品种嵌入的Conv-Transformer；每种结构都在相同59维输入、相同随机种子集合和相同组合规则下评估。模型选择指标应以验证期预测损失或Rank IC为主，最终测试期只报告一次。

第二优先级是提升经济边际而非模型复杂度。可研究成本感知损失、信号置信度过滤、换手惩罚、横截面排序损失、波动目标和板块分层。若20日Rank IC明显优于1日与5日，应让组合持仓机制与信号半衰期更一致，而不是每天对所有边界信号进行微调。

第三优先级是完善审计。应对每个特征记录来源时间、最大陈旧阈值、年度覆盖率 and 异常处理；对主力换月记录切换日期、前后合约与收益分解；对组合记录无法成交、流动性排除和GMM门控。只有这些审计通过后，才适合讨论更复杂的网络或实盘可行性。

14 结论

本项目完成了从基础1D-CNN到轻量Conv-Transformer多任务框架的多阶段探索。其真正的进步不仅是加入注意力或扩大特征维度，更在于逐步形成因果主力合约、决策与执行分离、扩展窗口验证、标签退出日约束、重叠样本降频、成本后回溯、流动性准入和历史拟合压力门控等较完整的量化研究链路。

历史结果显示，版本3的5日CNN方案在成本后明显亏损；版本5的Conv-Transformer双头方案改善到微弱正收益；版本6接入旧59因子后换手下降、3bp成本后仍略为正，但优势在5bp下几乎消失。由于版本间存在数据与协议变化，这些结果应被解释为探索轨迹，而不是Transformer或59因子的单独因果效果。

当前整合模型在方法上更为严谨：它使用现有846,963条合约日记录构建30品种因果主力面板，生成45个连续特征和14个质量标志，以 $[B, 59, 20]$ 输入预测未来20日截面超额收益，并准备在2022-2025年进行扩展窗口样本外评价。但与该代码绑定的正式输出尚未保存在项目目录中，因此最可信的结论是：研究框架已经具备重新训练和统一审计的条件，模型有效性仍需新一轮同口径实验确认。

对后续工作的核心建议是“先统一证据，再优化模型”。只有当数据版本、标签、测试期、成本与组合规则固定后，CNN、Transformer、多任务学习、品种嵌入和59维特征的增量价值才可被可靠识别。对于低信噪比的商品期货预测，透明的失败结果、严格的点时约束和可复现的实验协议，本身就是比单一漂亮净值更重要的研究产出。

A 当前59维输入清单

A.1 45个连续特征

当前连续特征按代码生成顺序列于table 6。所有字段进入模型前均追加__cs_robust_z后缀，表示同日横截面稳健标准化及板块去均值。

表 6: 当前整合模式的45个连续特征

序号	特征名	含义
1	return_1	1日收盘收益
2-6	momentum_5/10/20/60/120	多周期价格动量
7-9	trend_efficiency_20/60/120	净位移相对路径总波动的趋势效率
10-14	realized_vol_5/10/20/60/120	多周期年化实现波动率
15	downside_vol_20	20日下行收益波动率
16-17	realized_skew_20/60	收益分布偏度
18	high_low_range	当日高低价振幅
19	candle_body	收盘相对开盘的K线实体
20	close_settle_spread	收盘价相对结算价差
21	log_volume	对数成交量
22-23	volume_change_1/5	成交量短期变化
24-25	volume_z_20/60	成交量滚动标准分
26	log_open_interest	对数持仓量
27-28	oi_change_1/5	持仓量短期变化
29-30	oi_z_20/60	持仓量滚动标准分
31	volume_oi_turnover	成交量相对持仓量的换手
32	amihud_20	20日平均单位成交额价格冲击
33	roll_yield	主次合约期限结构收益
34-35	roll_change_5/20	期限结构变化
36-37	spot_momentum_5/20	经陈旧值过滤的现货动量
38	warehouse_level	仓单对数水平的60日标准分

序号	特征名	含义
39	warehouse_change_5	仓单5日变化
40	stock_level	库存对数水平的60日标准分
41	stock_change_5	库存5日变化
42	available_stock_level	可用库存对数水平的60日标准分
43	available_stock_change_5	可用库存5日变化
44	warehouse_change_1	仓单1日冲击
45	stock_change_1	库存1日冲击

A.2 14个缺失质量标志

质量标志对应较长回看期、低覆盖基本面和关键流动性变量，具体包括以下14项：

```
momentum_120; trend_efficiency_120; realized_vol_120;  
realized_skew_60; amihud_20; roll_yield; spot_momentum_20;  
warehouse_level; warehouse_change_5; stock_level; stock_change_5;  
available_stock_level; available_stock_change_5; volume_oi_turnover.
```

每个标志以__missing为后缀，取值为0或1。

B 30品种研究池

表 7: 当前代码固定的30品种研究池

板块	品种
黑色产业链	螺纹钢RB、热卷HC、铁矿石I、焦煤JM、焦炭J、硅铁SF
有色金属	铜CU、铝AL、锌ZN、镍NI、锡SN
贵金属	黄金AU、白银AG
能源化工	原油SC、燃料油FU、沥青BU、PTA、甲醇MA、聚乙烯L、聚丙烯PP、PVC
农产品	豆粕M、豆油Y、棕榈油P、玉米C、淀粉CS、白糖SR、棉花CF、菜粕RM
建材/化工补充	纯碱SA

C 历史结果完整费用表

表 8: 版本3、5、6在不同单边费用下的历史结果

版本	情景	年化收益	Sharpe	最大回撤	总收益	平均日换手
版本3	毛收益	-3.4095%	-0.4040	-21.7578%	-11.9438%	0.147858
	1bp	-4.1268%	-0.4991	-23.1432%	-14.3180%	0.147858
	3bp	-5.5456%	-0.6892	-26.3627%	-18.8762%	0.147858
	5bp	-6.9435%	-0.8791	-29.5439%	-23.1924%	0.147858
版本5	毛收益	2.5131%	0.4264	-8.6567%	9.5278%	0.140880
	1bp	1.7879%	0.3135	-9.4527%	6.7136%	0.140880
	3bp	0.3528%	0.0875	-11.0240%	1.2999%	0.140880
	5bp	-1.0621%	-0.1387	-12.5682%	-3.8395%	0.140880
版本6	毛收益	1.9579%	0.3074	-15.6125%	5.5095%	0.075664
	1bp	1.5699%	0.2539	-15.9578%	4.4025%	0.075664
	3bp	0.7982%	0.1470	-16.6441%	2.2232%	0.075664
	5bp	0.0323%	0.0401	-17.3248%	0.0892%	0.075664

D 正式新实验的建议输出结构

建议新建不可覆盖的实验目录，并在目录名中包含实验日期与协议。例如可使用短名称exp_h20，并在配置文件中记录完整日期和实验ID。其中应保存模型检查点、数据与配置报告、训练历史、样本外预测、逐日回测、持仓、主力换月、压力状态、特征列表、缺失审计、统一指标、成本情景、统计检验、分组收益、持有期稳健性、板块稳健性、流动性稳健性、信号延迟稳健性及全部图表。TeX报告只引用该目录中的相对路径，并在附录记录数据和代码SHA-256值。

参考文献

- [1] Fama, E. F. Efficient capital markets: A review of theory and empirical work[J]. The Journal of Finance, 1970, 25(2): 383–417.
- [2] Moskowitz, T. J., Ooi, Y. H., Pedersen, L. H. Time series momentum[J]. Journal of Financial Economics, 2012, 104(2): 228–250.
- [3] Gu, S., Kelly, B., Xiu, D. Empirical asset pricing via machine learning[J]. The Review of Financial Studies, 2020, 33(5): 2223–2273.
- [4] Vaswani, A., Shazeer, N., Parmar, N., et al. Attention is all you need[C]//Advances in Neural Information Processing Systems. 2017: 5998–6008.
- [5] Newey, W. K., West, K. D. A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix[J]. Econometrica, 1987, 55(3): 703–708.
- [6] Efron, B., Tibshirani, R. J. An Introduction to the Bootstrap[M]. New York: Chapman & Hall, 1993.
- [7] Huber, P. J. Robust estimation of a location parameter[J]. The Annals of Mathematical Statistics, 1964, 35(1): 73–101.
- [8] Amihud, Y. Illiquidity and stock returns: Cross-section and time-series effects[J]. Journal of Financial Markets, 2002, 5(1): 31–56.
- [9] Bishop, C. M. Pattern Recognition and Machine Learning[M]. New York: Springer, 2006.